

並列分散処理 (ネットワークシステム) 第7章 Web

山内 利宏

岡山大学 工学部 工学科
情報・電気・数理データサイエンス系
情報工学コース

Web

- インターネット上に分散されたサーバ上に存在するドキュメントにアクセスするために、開発された技術
- Webドキュメント
 - 多くの場合、HTML (Hyper Text Markup Language) で記述される
 - あるドキュメントが、他のドキュメントへのリンクを含むハイパーテキストとして記述される

HTTP

- WebブラウザとWebサーバ間の通信プロトコル
 - アプリケーション層のプロトコル
- TCP/IPを用いる
- ユーザがブラウザを操作することで、コネクションが確立
- Webブラウザからの要求(HTTPリクエスト)が、Webサーバに送られる
- Webサーバは、応答(HTTPレスポンス)をWebブラウザに返却する

HTTPの特徴(1.1以降)

- HTTPキープアライブ(HTTP Keep-Alive)
 - TCP接続を複数のHTTPリクエスト/レスポンスを送受信するよう維持
 - HTTPコネクションの再利用可能に
- ステートレスのプロトコル
 - Webサーバは過去のリクエストや状態を管理不要
 - スケールアウトしやすい
- クッキー(HTTP Cookie)
 - Webサーバからの情報を保存
 - Webサーバからは, 以前の接続情報を参照可能
 - ◆ セッション変数を使って, ログイン状態の保持など可能に

Webブラウザとサーバ

■ Webブラウザ

- HTMLで記述されたWebドキュメントを表示するアプリケーション(レンダリング)
- Webサーバから返却されるすべての形式のWebドキュメントを表示する必要がある
- Webサーバは、ドキュメントの形式をMIME形式で指定し、ブラウザは指定された形式に応じて、プラグインかヘルパアプリケーションを起動する

■ Webサーバ

- Webブラウザからの要求に応じて、該当するドキュメントを返却する
- ドキュメントを返却するだけでなく、外部のプログラムを呼び出す機能を持つ

HTTPリクエスト

- リクエスト行
 - メソッド (GETとPOSTがよく用いられる)
 - リファレンス
 - バージョン情報
- ヘッダ行
 - リクエストに対する追加情報を記述する
 - ◆ パラメータ属性など
- HTTPボディ
 - Webサーバへ送信するメッセージ本体

HTTPレスポンス

- ステータス行
- ヘッダ行
- HTTPボディ

意 味	コード	説 明
情 報	100	サーバが要求を処理することを同意
成 功	200	要求が成功
転 送	301	該当ページは移動した
	304	クライアントのキャッシュが有効
クライアントの誤り	400	不正なリクエスト
	403	アクセス権のないページへのアクセス
	404	該当ページが存在しない
サーバの誤り	500	サーバの内部誤り
	503	再試行

HTTPヘッダ

- 付加的な情報を記述
 - Content-Typeにより, Webドキュメントの形式を指定
 - ◆ plain, html, xml, gif, jpeg, x-gzip, pdf, ...
 - Host, Content-Length, Last-Modifiedなどのヘッダがある

Web API

- HTTP/HTTPSを介して利用されるAPI
 - RESTとSOAPの二種類
- REST
 - HTTPリクエスト送信時, GET, POST, PUT, DELETE等のメソッドを利用してリクエストを送信
 - レスポンスは, XMLやJSONのデータ形式で受取
- SOAP
 - HTTPのリクエストとレスポンスにXMLを利用
- REST APIを公開しているサイト (Art Institute of Chicago)
 - <https://api.artic.edu/api/v1/artworks/search?q=cats>
 - <https://api.artic.edu/api/v1/artworks/search?q=sunflowers>
 - <https://api.artic.edu/api/v1/artworks/<作品ID>>

REST (Representational State Transfer)

- リソース(資源)を, URL を使ってアクセス
- 操作はHTTPメソッド(GET/POST/PUT/DELETEなど)を利用
- RESTの概要
 - クライアントとサーバの分離
 - ステートレス
 - 統一インターフェース
 - ◆ URIでリソースを一意に識別
 - 例: /users/10
- 試せるサイト
 - <https://zip.cgis.biz/>
 - <https://zip.cgis.biz/xml/zip.php?zn=7008530>

プログラム呼び出し

- Webサーバでアプリケーションを実行し、結果を返す必要が出てきた
 - 文書検索システムや予約システムなど
- CGI(Common Gateway Interface)を用いて、Webサーバからアプリケーションの実行を実現
- HTMLのフォームからWebサーバへHTTPリクエストを送信
- Webサーバは、HTTPリクエストを解析し、パラメータ値を設定し、CGIプログラムを実行
- Webサーバは、CGIプログラムの結果から、Webドキュメントを作成し、ブラウザに結果を返す

負荷分散(1/3)

- キャッシング
 - Webブラウザ
 - ◆ よくアクセスするデータをメモリやローカルディスクに保持
 - プロキシサーバ
 - ◆ Webブラウザから要求を受け取り, Webブラウザの代わりにWebサーバと通信を行う
 - ◆ Webドキュメントをローカルディスクに保持
 - ◆ 利点: 利用者間でキャッシュを共有できる
 - WebコンテンツチェックやURLチェックなどのセキュリティ機能の導入
 - 問題点
 - ◆ キャッシュの一貫性
 - ◆ まず, 更新されたかどうかを問い合わせる方法
 - ◆ 有効時間を決めて, 更新の問い合わせ

負荷分散(2/3)

- レプリケーション
 - サイト内レプリケーション
 - ◆ クラスタ構成を用いて、複数のWebサーバにHTTPリクエストを分配する
 - サイト間レプリケーション
 - ◆ 広域に分散した複数のWebサイトに、Webドキュメントの完全な複製を配置する方法
 - ◆ ミラーリングとも呼ばれる
 - ◆ 複製先のWebサイトをミラーサイトと呼ぶ
- リバースプロキシ
 - Webサーバのフロントエンドにプロキシサーバを設置
 - オリジンサーバにリクエストを振り分け(負荷分散)
 - キャッシュを利用して代理でレスポンスを返却

負荷分散(3/3)

- CDN(Content Delivery Network)
 - 世界中のネットワークにWebサーバを分散配置
 - どこからアクセスしても, Webコンテンツを効率的に配信できるようにしたネットワーク
- クライアントとWebサーバの物理的な距離が, 応答時間に影響
 - クライアントに近い場所にWebサーバを設置できれば, アクセス時間を改善可能(負荷分散にも)
- 仕組み
 - DNSの名前解決時に, CDN事業者のDNSに再接続して, 最寄りのサーバのIPアドレスが返却
 - 返却されたIPアドレスを使って接続

セキュリティ

- アクセス制御
 - Webサーバは不特定多数の計算機から接続される
 - Webサーバが不正なアクセスを受けると、内部のサーバに不正アクセスされる可能性がある
- 制御対象
 - インターネット→Webサーバ
 - Webサーバ→イントラネット
- ファイアウォールを利用する
- インターネットへ公開するWebサーバは、非武装地帯(DMZ)と呼ばれる領域に配置する